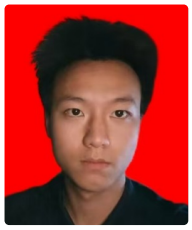
黄慕鑫



18627288501 hmx421083@stu.xjtu.edu.cn

https://muxin-homepage.vercel.app/

教育经历

西安交通大学 | 软件工程 | 本科 | 大二

主修：高等数学 线性代数 政治经济学 微观经济学 程序设计等

工作经历

未定义文化技术有限公司 | infra工程师 | 2026.7.1-2026.9.8

针对 MiniCPM 4.5 原生 PyTorch 推理框架仅支持单请求串行执行、无法实现单卡多会话服务，以及 vLLM-Omni 在流式推理中存在输出碎字、重复字符、会话抢答和结果串扰等问题，对模型推理链路进行服务化升级：拆分 Prefill 与 Decode 阶段，设计请求队列和动态批处理调度器，根据会话状态持续完成请求入批、退出及 Batch 重组；为每个会话独立维护输入 Token、生成位置、采样参数、停止条件和流式输出状态，避免并发请求之间相互干扰；实现基于 KV Page 的分页式 KV Cache 管理，通过 Page 分配、Block Table 映射、按需扩容和会话结束回收，减少固定长度缓存造成的显存浪费与碎片化；，最终使原生框架具备单卡多会话并发、动态批处理、分页 KV Cache 和稳定流式输出能力，提升 GPU 利用率、推理吞吐及长时间运行稳定性。

项目经历

量化科研实习 | 实习生 | 2025.12-2026.7 | 西安交通大学数统学院

负责前沿论文的研读与复现，将Kronos等前沿科研模型接入到更完整的量化研究流程中：包括 A 股/港股 K 线数据获取与整理、基于预训练模型的价格序列预测、预测结果可视化、历史回测、策略验证。以及基于本地数据集上的微调等工作。完成GNN股票市场建模工作https://github.com/muxinhuang51-web/my-GNN-main-for-trading

code llm科研实习 | 实习生 | 2026.8.15 | 浙江大学软件学院

系统分析大规模 ISA 迁移中的源码、Bazel 构建、依赖、测试、发布和生产调度链路，完成 single-arch 到 multiarch 的迁移架构设计。设计基于 LLM Agent 的构建失败定位、BUILD 修改、自动测试和补丁迭代流程，覆盖 intrinsic、ABI、内存模型及跨架构依赖问题